ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

HỌC LIÊN KẾT VÀ QUẢN LÝ TÀI NGUYÊN TRONG MẠNG IoT CÓ UAV

Federated Spatio-Temporal Policy Learning for Efficient Resource Management in UAV-Assisted IoT Edge Networks

Bài báo của Xiaoteng Yang và cộng sự
IEEE Internet of Things Journal, 2026 (bản tác giả)
DOI: 10.1109/JIOT.2026.3727888

ONE LOVE. ONE FUTURE.

NỘI DUNG

1. Giới thiệu về federated learning
2. System model and problem formulation
3. FSTPO framework
4. Hướng mở rộng dựa trên bản thảo JNCA

- Phần 1: FL, mô hình bài toán và mã giả FedAvg.
- Phần 2: mô hình hệ thống và đầy đủ công thức (1)–(15).
- Phần 3: sơ đồ FSTPO và các cơ chế chính.
- Phần 4: hướng mở rộng dựa trên bản thảo JNCA.

PHẦN 1

FEDERATED LEARNING

Khái niệm, bài toán tối ưu và thuật toán FedAvg

Federated learning là gì?

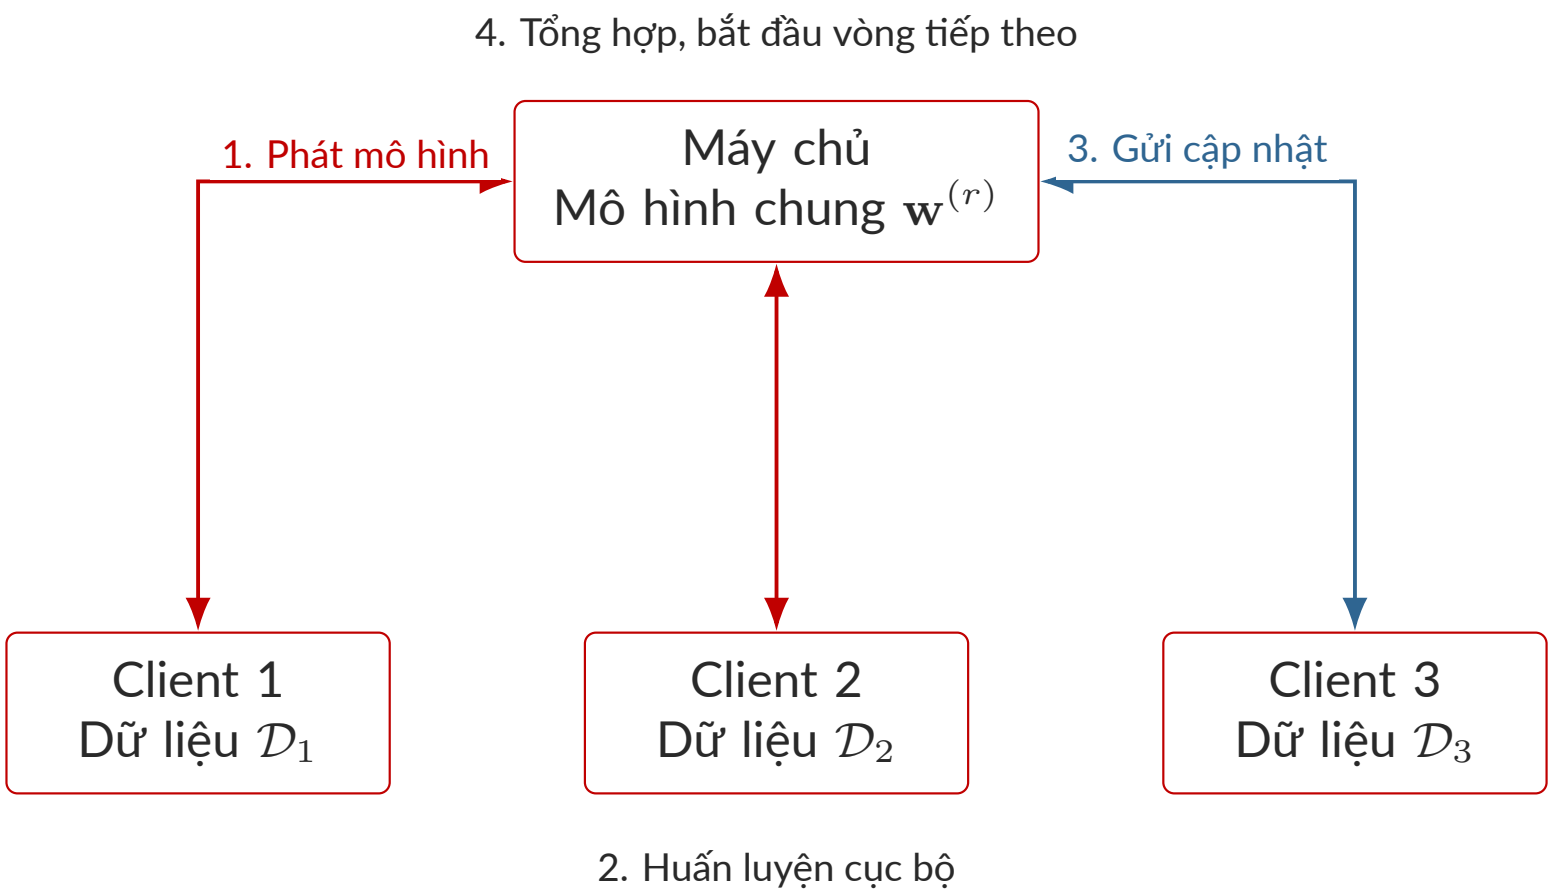
Nhiều thiết bị cùng học một mô hình, giữ dữ liệu huấn luyện tại chỗ.

	Tập trung	**Liên kết (FL)**
Dữ liệu	Tập hợp tại máy chủ	Lưu ở thiết bị
Huấn luyện	Máy chủ thực hiện	Thiết bị thực hiện
Trao đổi	Dữ liệu gốc	Trọng số/gradient

Client: giữ dữ liệu, huấn luyện.
Server: điều phối, tổng hợp cập nhật.

Nguồn: Google Cloud, What is federated learning?

Một vòng học liên kết



Chỉ cập nhật mô hình đi qua mạng; dữ liệu gốc ở client.

Nguồn: Google Cloud, What is federated learning?

FedAvg: ví dụ tổng hợp mô hình

Với tập client tham gia $\mathcal{S}_r$, một cách lấy trung bình có trọng số là

$$\mathbf{w}^{(r+1)} = \sum_{m \in \mathcal{S}_r} \frac{n_m}{\sum_{j \in \mathcal{S}_r} n_j} \mathbf{w}_m^{(r+1)}.$$

- n_m: số mẫu của client m; $\mathbf{w}_m^{(r+1)}$: tham số sau học cục bộ.
- Client có nhiều mẫu hơn có trọng số lớn hơn.

Ví dụ minh họa với một tham số vô hướng:

$$n_1 = 100,\ w_1 = 2; \qquad n_2 = 300,\ w_2 = 4.$$

$$w_{\text{mới}} = \frac{100}{400} \cdot 2 + \frac{300}{400} \cdot 4 = 3.5.$$

Nguồn: McMahan và cộng sự, AISTATS 2017, FedAvg. Ví dụ số tự xây dựng, không phải kết quả paper UAV.

Các dạng federated learning

Dạng	Mẫu dữ liệu	Đặc trưng
Horizontal FL	Khác nhau	Giống nhau
Vertical FL	Trùng nhau	Khác nhau
Federated transfer learning	Khác nhau	Khác nhau

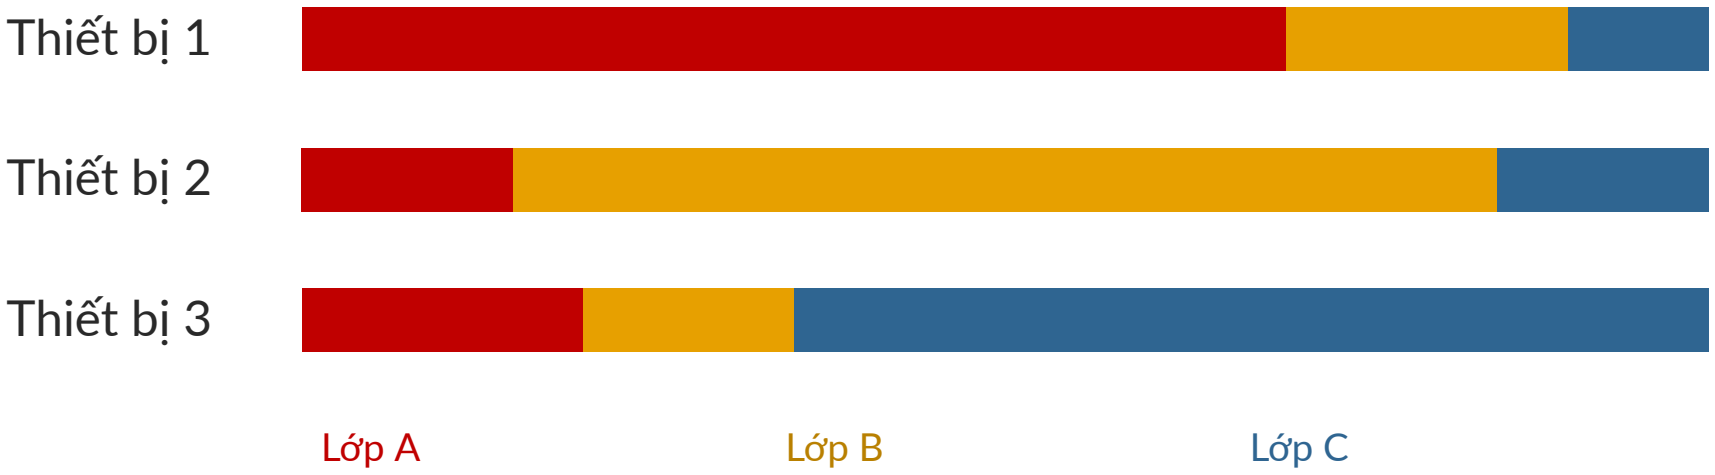
Ví dụ horizontal FL: nhiều điện thoại học mô hình dự đoán từ.

Ví dụ vertical FL: các tổ chức có thuộc tính bổ sung về cùng khách hàng.

Nguồn: Google Cloud, What is federated learning?

Non-IID: dữ liệu mỗi thiết bị khác nhau

Ví dụ minh họa: ba thiết bị có tỷ lệ ba lớp khác nhau.



- Mỗi client có thể học theo một hướng khác nhau.
- Chọn lặp lại một nhóm thiết bị có thể làm mô hình thiếu đại diện.
- Paper dùng độ lệch gradient để biểu diễn khác biệt dữ liệu.

Nguồn: McMahan và cộng sự (2017); paper UAV, Sec. I–II-B. Biểu đồ là dữ liệu minh họa tự xây dựng.

Lợi ích và thách thức

Lợi ích

- Hạn chế truyền dữ liệu nhạy cảm.
- Học từ dữ liệu phân tán.
- Có thể giảm tải truyền dữ liệu gốc.

Thách thức

- Dữ liệu non-IID.
- Phần cứng, kết nối khác nhau.
- Chi phí trao đổi nhiều vòng.
- Cập nhật có thể rò rỉ thông tin.

Có thể bổ sung secure aggregation hoặc differential privacy.

Nguồn: Google Cloud, What is federated learning?; McMahan và cộng sự (2017), Sec. 1, 5.

FedAvg: bài toán học chung

Có K thiết bị; thiết bị k giữ tập chỉ số $\mathcal{P}_k$, $n_k = |\mathcal{P}_k|$, $n = \sum_k n_k$. Mọi thiết bị dùng cùng kiến trúc mô hình $w \in \mathbb{R}^d$.

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^{n} f_i(w) = \sum_{k=1}^{K} \frac{n_k}{n} F_k(w), \qquad F_k(w) = \frac{1}{n_k} \sum_{i \in \mathcal{P}_k} f_i(w).$$

- $f_i(w) = \ell(x_i, y_i; w)$: lỗi dự đoán trên một mẫu.
- F_k: loss trung bình cục bộ; f: loss trên toàn bộ dữ liệu.
- Biến tối ưu là trọng số mô hình w; dữ liệu vẫn ở thiết bị.

Ý nghĩa: Thiết bị nhiều mẫu có trọng số lớn hơn; mục tiêu này không mặc định cân bằng công bằng giữa các thiết bị.

Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

FedAvg: input và output

Thành phần	Nội dung
Input dữ liệu	Các tập $\mathcal{P}_k$ phân tán, kích thước n_k; server không cần nhận mẫu thô.
Input mô hình	Kiến trúc chung, hàm loss khả vi, khởi tạo w_0.
Siêu tham số	Tỷ lệ tham gia C, số epoch cục bộ E, minibatch B, learning rate η.
Output mỗi vòng	Mô hình toàn cục mới w_{t+1} sau tổng hợp.
Output cuối	Mô hình w_T để suy luận; chất lượng đánh giá trên dữ liệu kiểm tra riêng.

Ý nghĩa: T là ngân sách số vòng dùng khi triển khai mã giả; không phải số epoch cục bộ E.

Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

Objective và constraint: đọc đúng phạm vi

Objective toán học: tối thiểu hóa empirical loss $f(w)$, thường không lồi với mạng neural.

Động cơ thiết kế: giảm số vòng giao tiếp để đạt chất lượng mục tiêu bằng cách tăng tính toán cục bộ.

- Bài FedAvg không đặt một hệ ràng buộc công suất, CPU hay deadline trong bài toán $\min_w f(w)$.
- Giả thiết thực nghiệm: tập client và dữ liệu cố định, cập nhật đồng bộ, chọn ngẫu nhiên một phần client mỗi vòng.
- Non-IID và mất cân bằng kích thước dữ liệu là đặc tính bài toán, không phải bất đẳng thức ràng buộc.
- Dữ liệu giữ tại client; gửi cập nhật không tự tạo bảo đảm differential privacy.

Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

Mã giả FedAvg: phía server

1. Khởi tạo mô hình chung w_0.
2. Với mỗi vòng $t = 0, \ldots, T-1$:
3. Chọn ngẫu nhiên tập S_t gồm $m = \max(\lfloor CK \rfloor, 1)$ client.
4. Gửi w_t; chạy song song $w_{t+1}^k \leftarrow \mathrm{ClientUpdate}(k, w_t)$ với $k \in S_t$.
5. Tính $n_{S_t} = \sum_{k \in S_t} n_k$ và tổng hợp

$$w_{t+1} = \sum_{k \in S_t} \frac{n_k}{n_{S_t}} w_{t+1}^k.$$

6. Trả về w_T khi hết ngân sách.

Mã giả diễn giải Algorithm 1: quy ước làm tròn được ghi rõ. Bản v4 sửa mẫu số thành tổng số mẫu của các client được chọn.

Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

Mã giả FedAvg: phía client

ClientUpdate(k, w)

1. Nhận $w = w_t$ từ server; tạo các minibatch kích thước B từ $\mathcal{P}_k$.
2. Với epoch $e = 1, \ldots, E$, duyệt từng minibatch b:

$$w \leftarrow w - \eta \nabla \ell(w; b).$$

3. Gửi mô hình cuối w về server; dữ liệu thô giữ tại chỗ.

Ý nghĩa: Mỗi client đi nhiều bước SGD từ cùng w_t, rồi server trung bình các điểm cuối.

E lớn hoặc B nhỏ làm tăng số bước local, xấp xỉ En_k/B. Điều này có thể giảm giao tiếp, nhưng tăng sai lệch giữa các cập nhật khi dữ liệu khác nhau. Không nên mặc định tăng E luôn tốt.

Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

Từ FedAvg đến bài toán tài nguyên FSTPO

- FedSGD với full batch và một bước local tổng hợp các gradient; FedAvg cho phép nhiều bước local trước khi giao tiếp.
- Cùng điểm xuất phát giúp việc trung bình mô hình có ý nghĩa; trung bình các mạng khởi tạo độc lập có thể cho kết quả xấu.
- Bài báo báo cáo giảm khoảng $10–100$ lần số vòng giao tiếp trong các thí nghiệm so với SGD đồng bộ; đây không phải bảo đảm cho mọi dữ liệu.
- FedAvg chọn ngẫu nhiên client; FSTPO học chọn client và cấp băng thông/CPU trong mạng UAV.

Ý nghĩa: Tầng học tối ưu w; tầng điều khiển tài nguyên chọn ai được học và với chi phí nào. Hai tầng liên quan nhưng có biến tối ưu khác nhau.

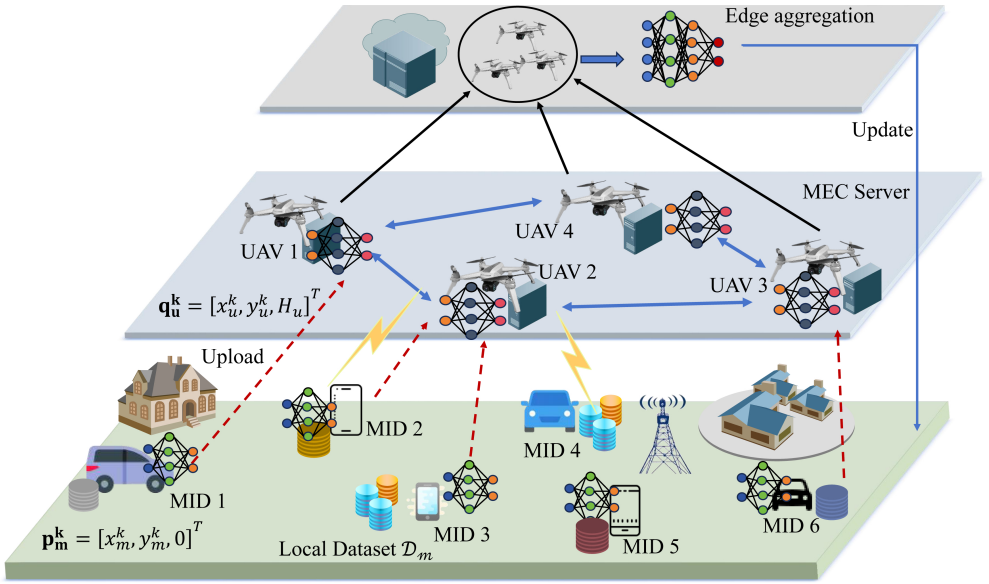
Nguồn: McMahan và cộng sự, 1602.05629v4, Sec. 2 và Algorithm 1 (có erratum).

PHẦN 2

SYSTEM MODEL AND PROBLEM FORMULATION

Mô hình hệ thống và bài toán tối ưu tài nguyên

Kiến trúc UAV hỗ trợ IoT



Hình 1 của paper.

- Thiết bị IoT học từ dữ liệu riêng.
- UAV mang máy chủ MEC, phục vụ offloading và tổng hợp theo cụm.
- Máy chủ mặt đất tổng hợp giữa các UAV qua backhaul riêng.

Bối cảnh: cứu hộ, giám sát vùng xa, triển khai tạm thời khi hạ tầng cố định hạn chế.

Nguồn: Yang và cộng sự, Sec. I-B, II-A–B, Hình 1. Số công thức theo paper gốc.

Tập hợp, thời gian và vị trí

$$\mathcal{U} = \{1, \ldots, U\}, \quad \mathcal{M} = \{1, \ldots, M\}, \quad \mathcal{K} = \{1, \ldots, K\}.$$

$$\mathbf{q}_u^k = [x_u^k, y_u^k, H_u]^T, \qquad \mathbf{p}_m^k = [x_m^k, y_m^k, 0]^T.$$

u, m, k	Chỉ số UAV, thiết bị và vòng giao tiếp.
$\mathbf{q}_u^k, \mathbf{p}_m^k$	Vị trí 3D của UAV và thiết bị ở vòng k.
H_u	Độ cao UAV u so với mặt đất.

Ý nghĩa: Di chuyển làm khoảng cách và chất lượng kênh thay đổi theo vòng.

Quỹ đạo là đầu vào của mô hình; bài toán (15) tối ưu lịch chọn, băng thông và CPU thiết bị.

Nguồn: Yang và cộng sự, Sec. II-A; các định nghĩa không đánh số. Số công thức theo paper gốc.

Ba nhóm biến quyết định

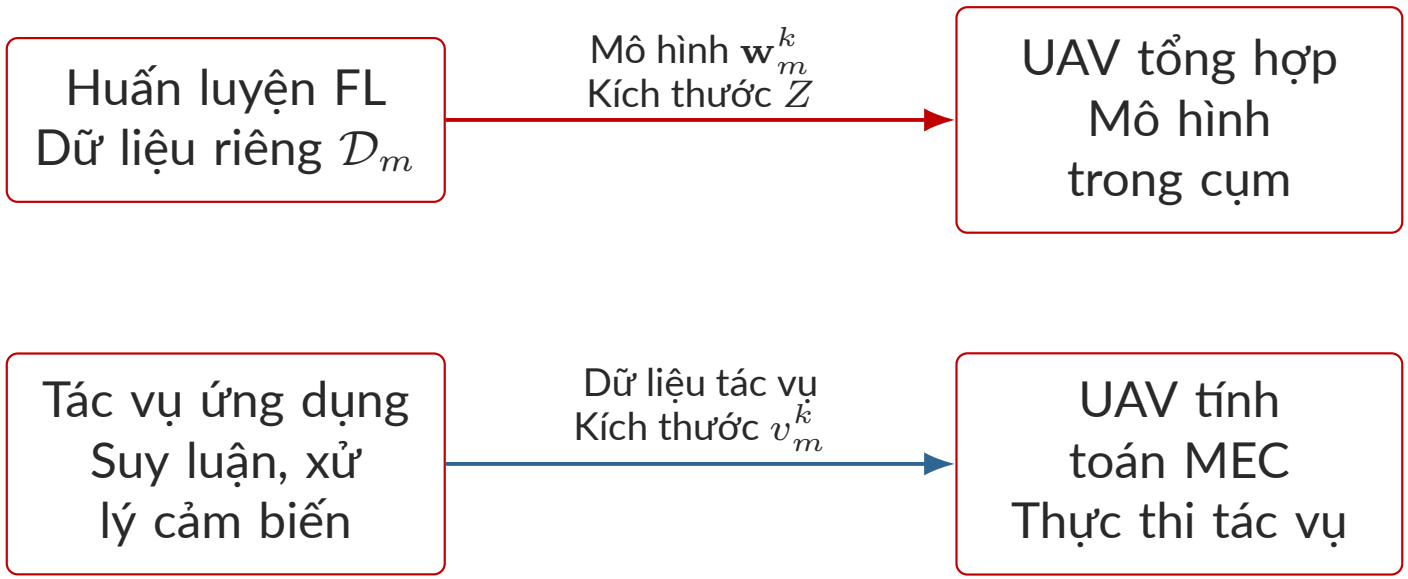
Biến	Quyết định
$s^k_{m,u} \in \{0,1\}$	Có chọn thiết bị m kết nối và offload đến UAV u hay không?
$b^k_{m,u} \geq 0$	Cấp bao nhiêu băng thông uplink cho kết nối đó?
f^k_m	Thiết bị m chạy CPU ở tần số nào khi huấn luyện?

$s^k_{m,u} = 1$: thiết bị tham gia và có liên kết với UAV u.
$s^k_{m,u} = 0$: không có liên kết phục vụ giữa cặp đó.

Tham số cho trước: công suất phát P_m, năng lực CPU UAV f_u, ngân sách $B_{\max}$.

Nguồn: Yang và cộng sự, Sec. II-A, II-C–F. Số công thức theo paper gốc.

Hai luồng công việc tại thiết bị và UAV



- Dữ liệu huấn luyện gốc giữ tại thiết bị.
- Tác vụ offload độc lập với quá trình huấn luyện FL.
- Hai luồng cùng tiêu thụ tài nguyên uplink và được điều khiển bởi $s_{m,u}^k$.

Nguồn: Yang và cộng sự, Sec. II-A, II-C. Số công thức theo paper gốc.

Hàm mất mát cục bộ

$$L_m(\mathbf{w}) = \frac{1}{D_m} \sum_{i=1}^{D_m} \ell(\mathbf{w}; \mathbf{x}_{m,i}, y_{m,i}), \tag{1}$$

$\mathcal{D}_m,\ D_m$	Tập dữ liệu của thiết bị m và số mẫu trong tập.
$\mathbf{x}_{m,i}, y_{m,i}$	Đặc trưng và nhãn của mẫu thứ i.
$\mathbf{w} \in \mathbb{R}^d$	Vector gồm d tham số của mô hình.
$\ell(\cdot)$	Loss trên một mẫu; L_m là loss trung bình tại thiết bị.

Ý nghĩa: Đo mức sai lệch của mô hình trên dữ liệu riêng của thiết bị m. Giá trị nhỏ hơn thể hiện mô hình khớp dữ liệu cục bộ tốt hơn.

Nguồn: Yang và cộng sự, Sec. II-B, (1). Số công thức theo paper gốc.

Hàm mất mát toàn cục

$$F(\mathbf{w}) = \sum_{m \in \mathcal{M}} \frac{D_m}{D_{\text{total}}} L_m(\mathbf{w}), \tag{2}$$

$D_{\text{total}} = \sum_m D_m$	Tổng số mẫu của toàn bộ thiết bị.
D_m / D_{total}	Trọng số của thiết bị m trong mục tiêu học.
$F(\mathbf{w})$	Loss trung bình có trọng số trên toàn bộ dữ liệu phân tán.

Ý nghĩa: Liên kết các mục tiêu cục bộ thành một mục tiêu học chung. Thiết bị có nhiều mẫu đóng góp nhiều hơn vào loss toàn cục.

Mẫu của thiết bị chưa được chọn ở một vòng vẫn thuộc tập dữ liệu định nghĩa mục tiêu toàn cục.

Nguồn: Yang và cộng sự, Sec. II-B, (2). Số công thức theo paper gốc.

Cập nhật mô hình tại thiết bị

$$\mathbf{w}_m^{(k,i)} = \mathbf{w}_m^{(k,i-1)} - \eta \widehat{\nabla} L_m(\mathbf{w}_m^{(k,i-1)}), \tag{3}$$

$i \in \{1, \ldots, I\}$	Bước cập nhật cục bộ; I là số bước SGD.
η	Tốc độ học.
$\widehat{\nabla} L_m$	Gradient ngẫu nhiên ước lượng từ dữ liệu cục bộ.

Ý nghĩa: Mỗi bước điều chỉnh tham số theo hướng làm giảm loss cục bộ. Chỉ thiết bị được chọn thực hiện huấn luyện.

$$\mathbf{w}_m^{(k,0)} = \mathbf{w}^{k-1}, \qquad \mathbf{w}_m^k = \mathbf{w}_m^{(k,I)}.$$

Nguồn: Yang và cộng sự, Sec. II-B, (3). Số công thức theo paper gốc.

Tổng hợp mô hình toàn cục

$$\mathbf{w}^k = \frac{\sum_{u\in\mathcal{U}}(\sum_{m\in\mathcal{M}} s^k_{m,u} D_m)\mathbf{w}^k_u}{\sum_{u\in\mathcal{U}}\sum_{m\in\mathcal{M}} s^k_{m,u} D_m}, \tag{4}$$

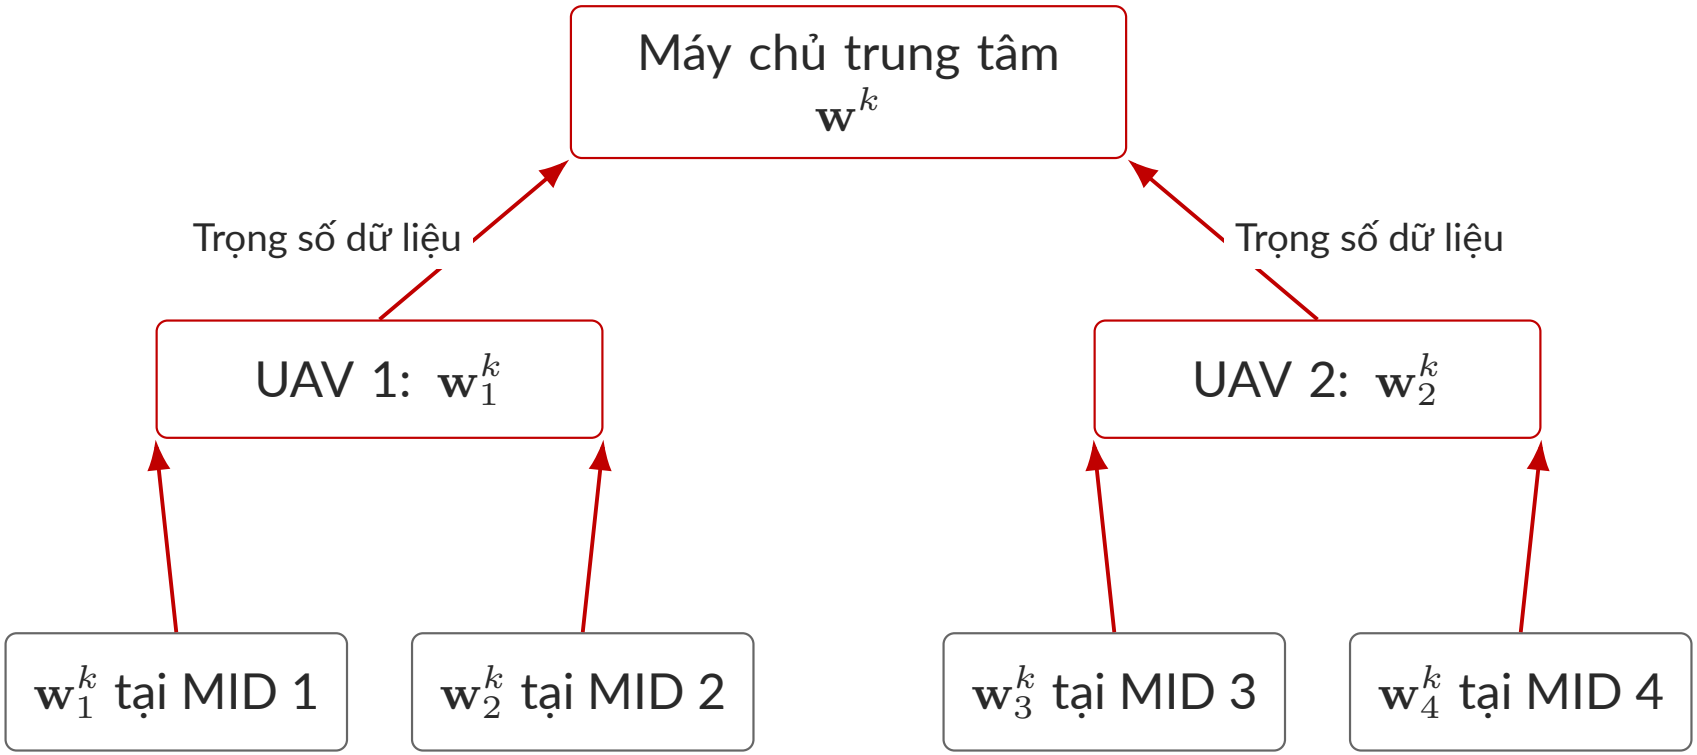
$\mathbf{w}^k_u$	Mô hình UAV u tổng hợp từ các thiết bị trong cụm.
$\sum_m s^k_{m,u} D_m$	Tổng số mẫu của các thiết bị được UAV u chọn.
$\mathbf{w}^k$	Mô hình chung sau tổng hợp giữa các UAV.

Ý nghĩa: Trọng số của mỗi UAV phản ánh lượng dữ liệu đang tham gia. Mô hình mới được phân phối ở vòng kế tiếp.

Giả sử có ít nhất một thiết bị tham gia để mẫu số khác 0.

Nguồn: Yang và cộng sự, Sec. II-B, (4). Số công thức theo paper gốc.

Sơ đồ tổng hợp hai cấp



Cấp 1: thiết bị gửi mô hình cho UAV phục vụ.
Cấp 2: máy chủ hợp nhất mô hình của các UAV theo (4).

Sơ đồ minh họa 2 UAV và 4 MID; số nút thực tế là U và M.

Nguồn: Yang và cộng sự, Sec. II-B, (4); sơ đồ vẽ lại. Số công thức theo paper gốc.

Độ lệch gradient do dữ liệu non-IID

$$(\delta_m^{k-1})^2 = \left\| \nabla L_m(\mathbf{w}^{k-1}) - \nabla F(\mathbf{w}^{k-1}) \right\|^2, \tag{5}$$

∇L_m	Hướng gradient thật trên dữ liệu của thiết bị m.
∇F	Hướng gradient thật của mục tiêu toàn cục.
δ_m^{k-1}	Độ lệch tính tại cùng mô hình $\mathbf{w}^{k-1}$.

Ý nghĩa: Giá trị lớn biểu thị hướng học cục bộ khác nhiều so với hướng học chung; đây là tín hiệu về sự không đồng nhất dữ liệu.

Nguồn: Yang và cộng sự, Sec. II-B, (5). Số công thức theo paper gốc.

Utility của hoạt động học liên kết

$$\Upsilon_{\mathrm{FL}}^{k} = \sum_{u \in \mathcal{U}} \sum_{m \in \mathcal{M}} s_{m,u}^{k} \frac{D_m}{D_{\mathrm{total}}} \exp[-\lambda(\delta_m^{k-1})^2], \tag{6}$$

$s_{m,u}^{k}$	Chỉ thiết bị được chọn mới đóng góp utility ở vòng k.
D_m / D_{total}	Phản ánh quy mô dữ liệu của thiết bị.
$\lambda > 0$	Điều chỉnh mức phạt độ lệch gradient.

Ý nghĩa: Ưu tiên thiết bị có nhiều dữ liệu và gradient ít lệch khỏi hướng toàn cục, đồng thời vẫn phải xét chi phí phục vụ.

$\Upsilon_{\mathrm{FL}}^{k}$ là đại lượng thay thế cho lợi ích học. Accuracy thực được kiểm tra riêng bằng $\mathrm{Acc}^{K} \geq \mathrm{Acc}_{\mathrm{target}}$.

Nguồn: Yang và cộng sự, Sec. II-B, (6). Số công thức theo paper gốc.

Khối lượng dữ liệu gửi uplink

$$\Omega_m^k = \underbrace{Z}_{\text{mô hình nén}} + \underbrace{v_m^k}_{\text{tác vụ offload}} .$$

Z	Kích thước mô hình sau lượng tử hóa và làm thưa gradient.
v_m^k	Kích thước dữ liệu tác vụ ứng dụng ở vòng k.
Ω_m^k	Tổng lượng dữ liệu thiết bị cần gửi lên UAV.

Ý nghĩa: Uplink phải tải cả cập nhật FL và dữ liệu tác vụ. Hai thành phần cùng quyết định thời gian truyền và năng lượng phát.

Quy trình nén được áp dụng thống nhất cho các thiết bị; không phải biến tối ưu trong (15). Khi tính tốc độ theo bit/s, đổi mọi kích thước về bit.

Nguồn: Yang và cộng sự, Sec. II-C; công thức không đánh số. Số công thức theo paper gốc.

Khoảng cách thiết bị–UAV

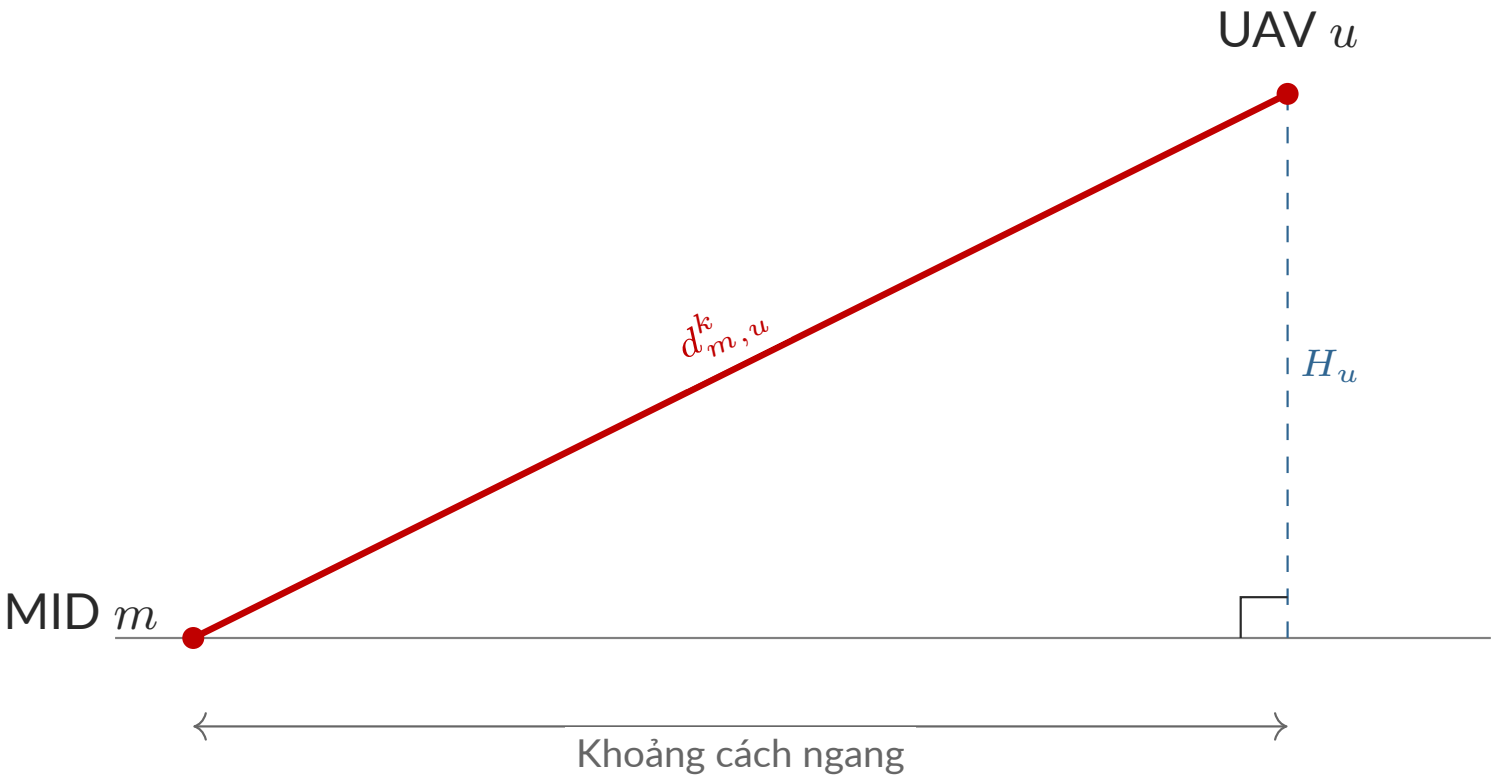
$$d_{m,u}^k = \sqrt{(x_u^k - x_m^k)^2 + (y_u^k - y_m^k)^2 + H_u^2}, \tag{7}$$

x_u^k, y_u^k	Tọa độ ngang của UAV.
x_m^k, y_m^k	Tọa độ thiết bị mặt đất.
H_u	Độ cao UAV; $d_{m,u}^k$ là khoảng cách 3D.

Ý nghĩa: Khoảng cách kết hợp độ lệch ngang và độ cao; thiết bị càng xa UAV thì suy hao truyền dẫn càng lớn trong mô hình kế tiếp.

Nguồn: Yang và cộng sự, Sec. II-C, (7). Số công thức theo paper gốc.

Hình học của liên kết không–mặt đất



Giữ nguyên độ cao, khi UAV dịch xa thiết bị theo phương ngang thì $d^k_{m,u}$ tăng và gain $h^k_{m,u}$ giảm.

Nguồn: Yang và cộng sự, Sec. II-A, II-C, (7)–(8); hình minh họa hình học. Số công thức theo paper gốc.

Gain kênh truyền quy mô lớn

$$h_{m,u}^{k} = \frac{\beta_0}{(d_{m,u}^{k})^2}, \tag{8}$$

$h_{m,u}^{k}$	Gain công suất kênh của liên kết thiết bị–UAV.
β_0	Gain tại khoảng cách tham chiếu theo quy ước paper.
$d_{m,u}^{k}$	Khoảng cách 3D từ (7).

Ý nghĩa: Paper dùng mô hình suy hao không gian tự do cho liên kết có xác suất LoS cao. Gain giảm theo bình phương khoảng cách.

Đây là gain quy mô lớn. Fading tức thời được đưa thêm vào mô hình độ tin cậy ở (12)–(13).

Nguồn: Yang và cộng sự, Sec. II-C, (8). Số công thức theo paper gốc.

Tốc độ truyền dữ liệu uplink

$$R_{m,u}^{k} = b_{m,u}^{k} \log_2 \left(1 + \frac{P_m h_{m,u}^{k}}{N_0 b_{m,u}^{k}} \right), \tag{9}$$

$b_{m,u}^{k}$	Băng thông cấp cho thiết bị (Hz).
P_m	Công suất phát của thiết bị (W).
N_0	Mật độ phổ công suất nhiễu (W/Hz).
$R_{m,u}^{k}$	Tốc độ truyền khả dụng (bit/s).

Ý nghĩa: Tốc độ phụ thuộc đồng thời băng thông, công suất và khoảng cách thông qua gain kênh. Tốc độ lớn giúp truyền xong nhanh hơn.

FDMA: mỗi UAV có quỹ $B_{\max}$ riêng, các quỹ không chồng lấn để loại nhiễu đồng kênh giữa UAV.

Nguồn: Yang và cộng sự, Sec. II-C, (9). Số công thức theo paper gốc.

Huấn luyện cục bộ: thời gian và năng lượng

$$t_m^{\text{comp},k} = \frac{ID_m c_m}{f_m^k}, \qquad E_m^{\text{comp},k} = \kappa_m (f_m^k)^2 (ID_m c_m).$$

I, D_m	Số bước học cục bộ và số mẫu dữ liệu.
c_m	Hệ số chi phí CPU để xử lý dữ liệu.
f_m^k, κ_m	Tần số CPU và hệ số điện dung hiệu dụng của thiết bị.

Ý nghĩa: Tăng tần số CPU làm thời gian học giảm nhưng năng lượng tính toán tăng theo bình phương tần số.

Giữ nguyên công thức paper. Paper định nghĩa D_m theo số mẫu nhưng ghi c_m là cycles/bit; cần quy đổi mẫu sang bit để nhất quán đơn vị khi tính số.

Nguồn: Yang và cộng sự, Sec. II-D; các công thức không đánh số. Số công thức theo paper gốc.

Truyền uplink: thời gian và năng lượng

$$\text{Thời gian uplink khi được chọn} = \frac{\Omega_m^k}{R_{m,u}^k},$$

$$E_{m,u}^{\text{comm},k} = s_{m,u}^k P_m \frac{\Omega_m^k}{R_{m,u}^k}.$$

Ω_m^k	Tổng kích thước mô hình và dữ liệu tác vụ.
$R_{m,u}^k$	Tốc độ uplink từ (9).
$s_{m,u}^k$	Kích hoạt chi phí truyền cho cặp được chọn.

Ý nghĩa: Năng lượng phát bằng công suất nhân thời gian. Tác vụ lớn hoặc kênh chậm làm năng lượng truyền tăng.

Tỷ số được đánh giá trên liên kết hoạt động, có tốc độ dương.

Nguồn: Yang và cộng sự, Sec. II-D; các biểu thức không đánh số. Số công thức theo paper gốc.

Tính toán biên trên UAV

$$t_{m,u}^{\text{edge},k} = \frac{v_m^k c_u}{f_u}, \qquad E_{u,m}^{\text{edge},k} = \kappa_u f_u^2 (v_m^k c_u).$$

v_m^k	Kích thước tác vụ thiết bị m offload lên UAV.
c_u	Số chu kỳ CPU cần xử lý một bit tác vụ.
f_u	Năng lực xử lý CPU đa lõi tổng hợp của UAV.
κ_u	Hệ số điện dung hiệu dụng của CPU UAV.

Ý nghĩa: UAV chịu thời gian và năng lượng để thực thi tác vụ được offload. Các chi phí này chỉ phát sinh khi $s_{m,u}^k = 1$.

Paper xem f_u là tham số cho trước, còn f_m^k của thiết bị là biến tối ưu.

Nguồn: Yang và cộng sự, Sec. II-D; các công thức không đánh số. Số công thức theo paper gốc.

Thời gian một vòng giao tiếp

Thời gian phục vụ một thiết bị:

$$t_{m,u}^{k} = t_{m}^{\mathrm{comp},k} + \frac{\Omega_{m}^{k}}{R_{m,u}^{k}} + t_{m,u}^{\mathrm{edge},k}.$$

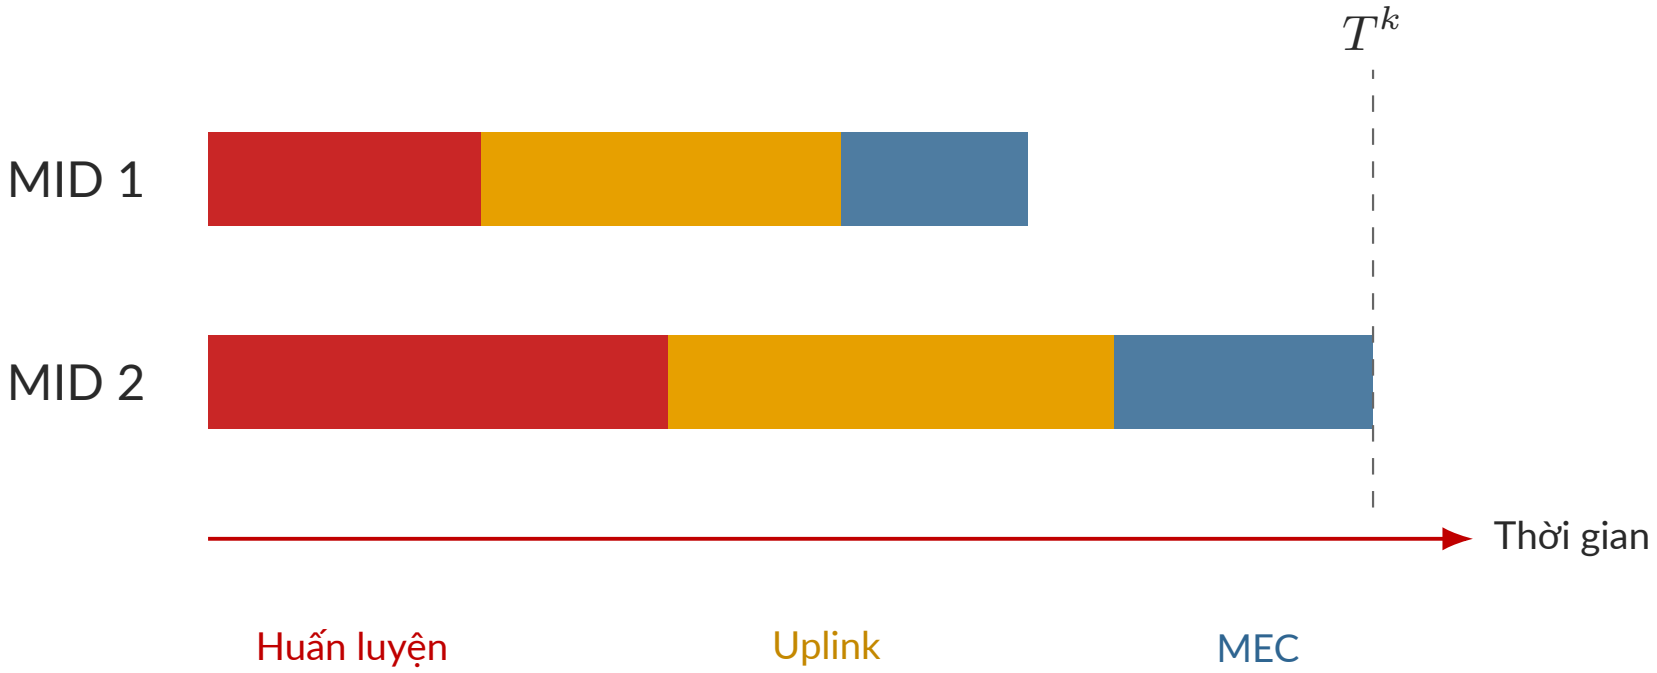
$$T^{k} = \max_{m\in\mathcal{M},u\in\mathcal{U}} \left\{ s_{m,u}^{k} \left(t_{m}^{\mathrm{comp},k} + \frac{\Omega_{m}^{k}}{R_{m,u}^{k}} + t_{m,u}^{\mathrm{edge},k} \right) \right\}. \tag{10}$$

$t_{m,u}^{k}$	Tổng thời gian học, truyền và xử lý biên của một cặp.
T^{k}	Viết gọn $T^{k} = \max_{m,u}\{s_{m,u}^{k} t_{m,u}^{k}\}$; thời gian do thiết bị được chọn chậm nhất quyết định.

Ý nghĩa: Đồng bộ theo vòng tạo hiệu ứng "thiết bị chậm": một liên kết hoặc CPU chậm có thể kéo dài cả vòng.

Nguồn: Yang và cộng sự, Sec. II-D, (10) và định nghĩa không đánh số. Số công thức theo paper gốc.

Minh họa đồng bộ theo thiết bị chậm nhất



Trong ví dụ: MID 2 quyết định thời gian hoàn thành vòng. Tăng tài nguyên cho MID 1 chưa chắc giảm T^k.

Độ dài các đoạn chỉ minh họa định tính, không phải số liệu mô phỏng.

Nguồn: Yang và cộng sự, Sec. II-D, (10); sơ đồ minh họa tự xây dựng. Số công thức theo paper gốc.

Tổng năng lượng hệ thống

Năng lượng phục vụ một cặp thiết bị–UAV:

$$E_{m,u}^{k} = E_{m}^{\mathrm{comp},k} + E_{m,u}^{\mathrm{comm},k} + E_{u,m}^{\mathrm{edge},k}.$$

$$E_{\mathrm{total}}^{k} = \sum_{u\in\mathcal{U}} \sum_{m\in\mathcal{M}} s_{m,u}^{k} E_{m,u}^{k}. \tag{11}$$

$E_{m,u}^{k}$ Gộp năng lượng học tại thiết bị, uplink và MEC.

$s_{m,u}^{k}$ Chỉ cộng năng lượng của các cặp đang được phục vụ.

Ý nghĩa: Đánh giá chi phí năng lượng của toàn bộ các quyết định trong một vòng, gồm cả thiết bị và CPU UAV.

Giữ nguyên công thức paper: $E^{\mathrm{comm},k}$ đã chứa s. Với $s \in \{0, 1\}$, nhân thêm s ở tổng không làm thay đổi kết quả. Năng lượng bay treo không được tính vì độc lập với các biến tối ưu.

Nguồn: Yang và cộng sự, Sec. II-D, (11) và định nghĩa không đánh số. Số công thức theo paper gốc.

SNR tức thời

$$\gamma_{m,u}^{k} = \frac{P_m \widetilde{h}_{m,u}^{k}}{N_0 b_{m,u}^{k}}, \tag{12}$$

$\widetilde{h}_{m,u}^{k}$	Gain tức thời có fading, phân bố mũ với trung bình $h_{m,u}^{k}$.
$P_m \widetilde{h}_{m,u}^{k}$	Công suất tín hiệu nhận.
$N_0 b_{m,u}^{k}$	Công suất nhiễu trong băng thông được cấp.

Ý nghĩa: SNR so sánh tín hiệu với nhiễu. Dù vị trí và băng thông giữ nguyên, fading vẫn có thể làm SNR biến động.

Giải mã thành công nếu $\gamma_{m,u}^{k} \geq \gamma_{\mathrm{th}}$; ngược lại xảy ra outage.

Nguồn: Yang và cộng sự, Sec. II-E, (12). Số công thức theo paper gốc.

Xác suất truyền thành công

$$\Gamma_{m,u}^{k} = \Pr(\gamma_{m,u}^{k} \geq \gamma_{\mathrm{th}}) = \exp\left(-\frac{\gamma_{\mathrm{th}} N_0 b_{m,u}^{k}}{P_m h_{m,u}^{k}}\right), \tag{13}$$

γ_{th}	Ngưỡng SNR dùng để giải mã, ở thang tuyến tính trong công thức.
$\Gamma_{m,u}^{k}$	Xác suất thành công, nằm trong $[0, 1]$.
$\Gamma_{\min}$	Ngưỡng xác suất thành công tối thiểu cần đạt.

Ý nghĩa: Chuyển biến động kênh ngẫu nhiên thành một chỉ tiêu độ tin cậy để đưa vào ràng buộc tối ưu.

Với công suất phát cố định, tăng b cũng tăng nhiễu trong mô hình này. $\Gamma_{\min}$ là xác suất, không phải giá trị dB.

Nguồn: Yang và cộng sự, Sec. II-E, (13). Số công thức theo paper gốc.

Utility hệ thống trong một vòng

$$U^k = \omega_1 \Upsilon_{\mathrm{FL}}^k - \omega_2 E_{\mathrm{total}}^k - \omega_3 T^k, \tag{14}$$

$\omega_1 > 0$	Trọng số của lợi ích học FL.
$\omega_2 > 0$	Mức phạt tiêu thụ năng lượng.
$\omega_3 > 0$	Mức phạt thời gian hoàn thành vòng.

Ý nghĩa: Chính sách tốt cần tạo lợi ích học cao với chi phí năng lượng và độ trễ phù hợp. Tăng một thành phần có thể làm xấu thành phần khác.

Các trọng số được hiệu chỉnh để các đại lượng khác đơn vị có thang số so sánh phù hợp.

Nguồn: Yang và cộng sự, Sec. II-F, (14). Số công thức theo paper gốc.

Bài toán tối ưu chung

$$
\begin{aligned}
\max_{s^k_{m,u}, b^k_{m,u}, f^k_m} \quad & \sum_{k=1}^{K} U^k \\
\text{s.t.} \quad & (\text{C1})\ s^k_{m,u} \in \{0,1\}, && \forall m,u,k, \\
& (\text{C2})\ \sum_{u\in\mathcal{U}} s^k_{m,u} \le 1, && \forall m,k, \\
& (\text{C3})\ \sum_{m\in\mathcal{M}} s^k_{m,u} b^k_{m,u} \le B_{\max}, && \forall u,k, \\
& (\text{C4})\ b^k_{m,u} \ge 0, && \forall m,u,k, \\
& (\text{C5})\ f^{\min}_m \le f^k_m \le f^{\max}_m, && \forall m,k, \\
& (\text{C6})\ s^k_{m,u} t^k_{m,u} \le T_{\max}, && \forall m,u,k, \\
& (\text{C7})\ \Gamma^k_{m,u} \ge \Gamma_{\min}, && \forall m,u,k, \\
& (\text{C8})\ \mathrm{Acc}^K \ge \mathrm{Acc}_{\text{target}}.
\end{aligned}
\tag{15}
$$

Ý nghĩa: Tối đa tổng utility trong K vòng bằng ba nhóm biến s, b, f_m, đồng thời đáp ứng giới hạn tài nguyên và chất lượng dịch vụ.

Nguồn: Yang và cộng sự, Sec. II-F, (15). Số công thức theo paper gốc.

Ý nghĩa các ràng buộc tài nguyên

Ràng buộc	Giải thích ngắn
(C1)	s là quyết định nhị phân: chọn hoặc không chọn.
(C2)	Mỗi thiết bị có thể được tối đa một UAV phục vụ trong một vòng.
(C3)	Tổng băng thông của các thiết bị được chọn không vượt $B_{\max}$ của UAV.
(C4)	Băng thông không âm.
(C5)	CPU thiết bị hoạt động trong khoảng phần cứng $[f_m^{\min}, f_m^{\max}]$.

Các giới hạn này xác định quyết định nào có thể thực thi trên mạng.

Nguồn: Yang và cộng sự, Sec. II-F, (15), (C1)–(C5). Số công thức theo paper gốc.

Ý nghĩa các ràng buộc chất lượng

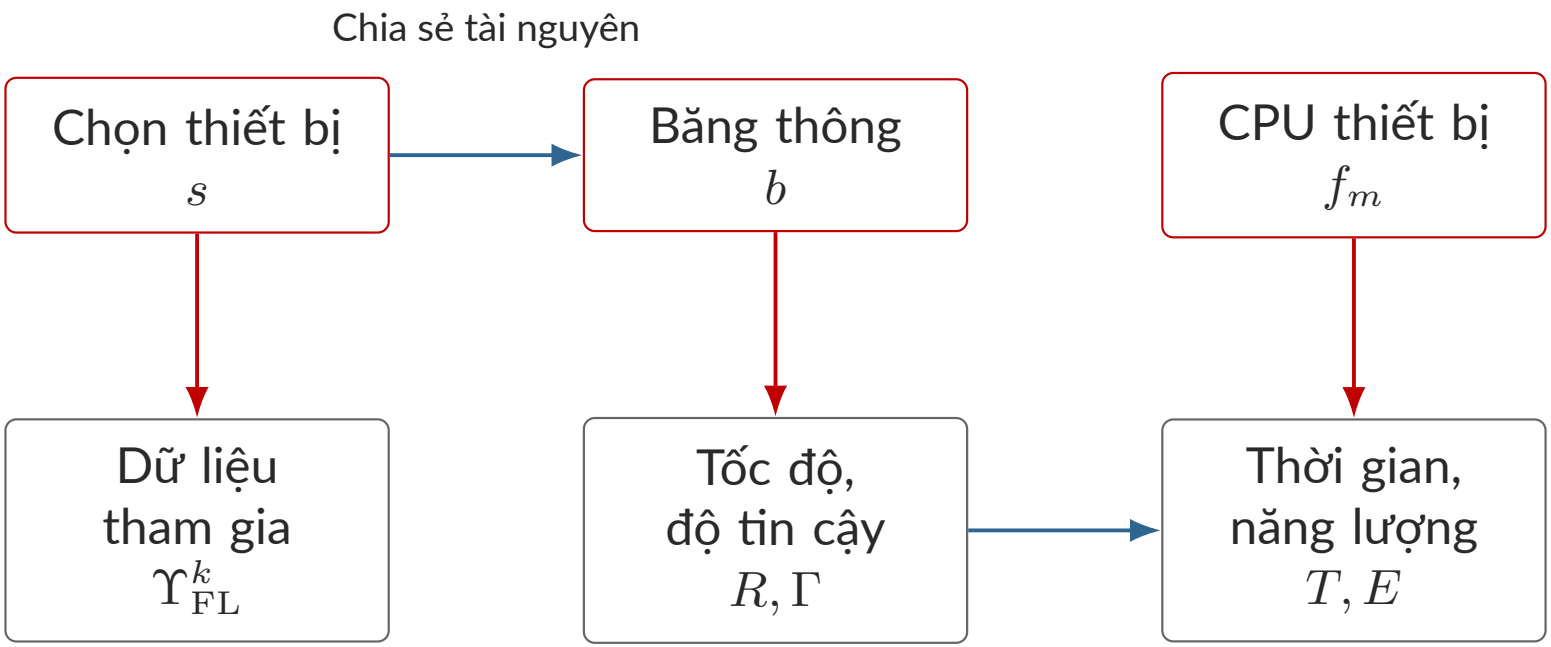
Ràng buộc	Giải thích ngắn
(C6)	Thiết bị được chọn hoàn thành dịch vụ trong $T_{\max}$.
(C7)	Xác suất truyền thành công đạt ít nhất $\Gamma_{\min}$.
(C8)	Mô hình sau K vòng đạt accuracy mục tiêu trên tập validation độc lập.

Lưu ý khi đọc paper:

- (C7) được viết cho mọi cặp (m, u), không có s đi kèm.
- Acc^K là accuracy đo thực tế; khác với utility thay thế Υ^k_{FL}.

Nguồn: Yang và cộng sự, Sec. II-B, II-F, (15), (C6)–(C8). Số công thức theo paper gốc.

Sự liên kết giữa các quyết định



- Biến nhị phân và liên tục cùng xuất hiện, các quan hệ phi tuyến.
- Lựa chọn ở vòng hiện tại ảnh hưởng mô hình ở những vòng sau.

Kết quả: bài toán MINLP động, dẫn tới cách tiếp cận học chính sách FSTPO.

Nguồn: Yang và cộng sự, Sec. II-F–III; sơ đồ diễn giải. Số công thức theo paper gốc.

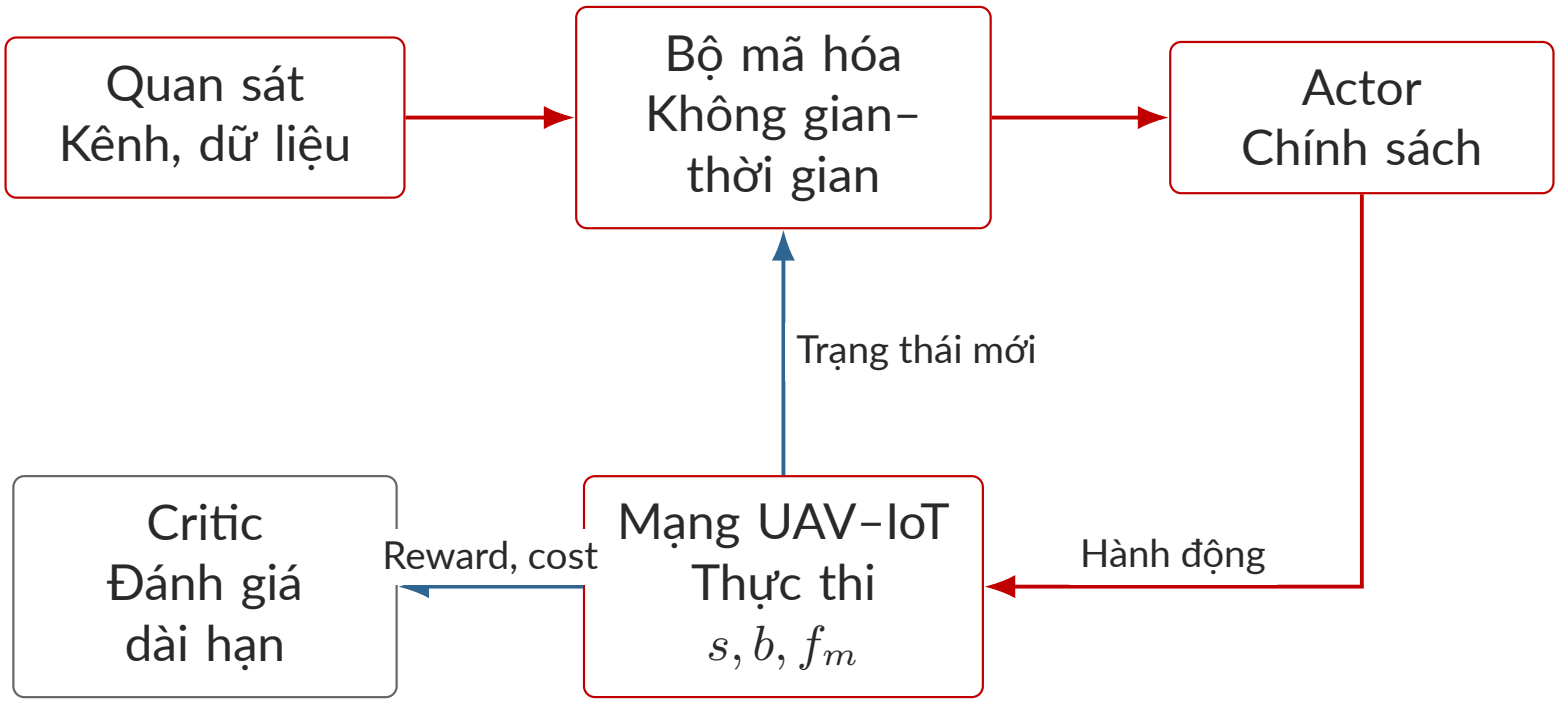
PHẦN 3

FSTPO FRAMEWORK

Trực giác, sơ đồ và các công thức chính

FSTPO: vòng ra quyết định

Federated Spatio-Temporal Policy Optimization. Mỗi UAV là một tác tử.



Actor chọn hành động. Critic đánh giá để cải thiện Actor trong giai đoạn huấn luyện.

Nguồn: Yang và cộng sự, Sec. III, III-B–D; sơ đồ đơn giản hóa Hình 2. Số công thức theo paper gốc.

Trạng thái và hành động của UAV

$$\mathbf{s}_u^k = (\mathbf{H}_u^{k-\tau:k}, \mathbf{D}_u^k, \boldsymbol{\delta}_u^{k-1}, B_{\text{rem}}^k). \tag{21}$$

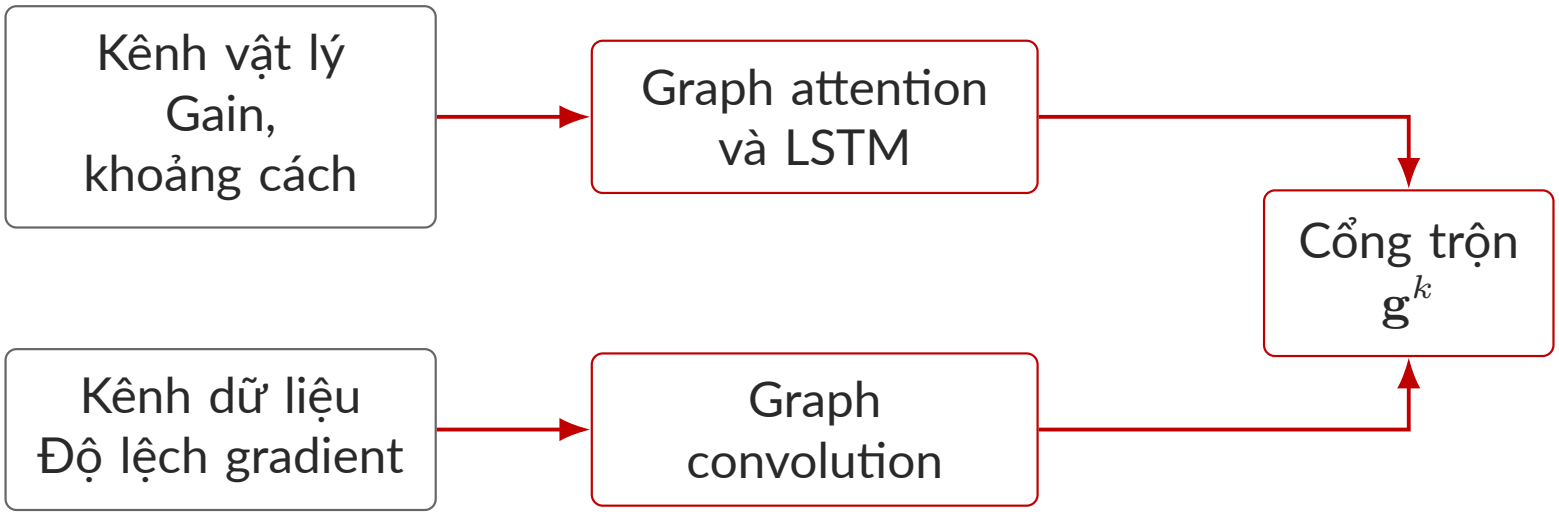
$\mathbf{H}_u^{k-\tau:k}$	Lịch sử kênh trong cửa sổ thời gian.
$\mathbf{D}_u^k$	Khoảng cách đến các thiết bị.
$\boldsymbol{\delta}_u^{k-1}$	Thông tin độ lệch gradient, phản ánh non-IID.
B_{rem}^k	Băng thông còn lại.

Ý nghĩa: UAV quan sát cả điều kiện truyền thông và thông tin liên quan tới dữ liệu trước khi chọn s, b, f_m.

$\mathbf{s}_u^k$ là vector trạng thái; $s_{m,u}^k$ là biến chọn thiết bị.

Nguồn: Yang và cộng sự, Sec. III-B, (21). Số công thức theo paper gốc.

Bộ mã hóa hai kênh

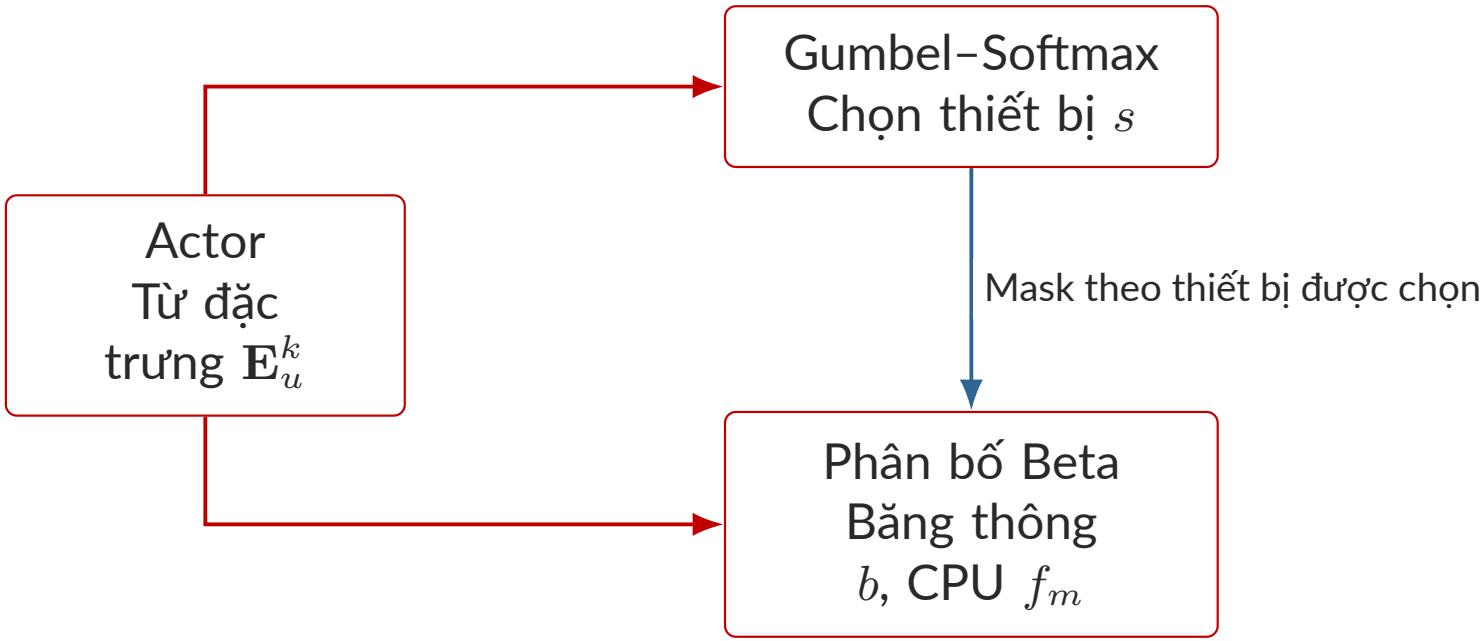


$$\mathbf{E}_u^k = \mathbf{g}^k \odot \mathbf{h}_{u,\text{phy}}^k + (1 - \mathbf{g}^k) \odot \mathbf{h}_{u,\text{fed}}^k. \tag{20}$$

Ý nghĩa: Trộn đặc trưng vật lý và dữ liệu thành biểu diễn chung cho Actor–Critic. $\odot$ là phép nhân theo phần tử.

Nguồn: Yang và cộng sự, Sec. III-A, (16)–(20), Thuật toán 1. Số công thức theo paper gốc.

Học hành động rời rạc và liên tục



- Khi học: làm mềm lựa chọn rời rạc để truyền gradient.
- Khi suy luận: dùng argmax để lấy quyết định chọn cứng.
- Mask gắn phân bổ tài nguyên với quyết định chọn thiết bị.

Nguồn: Yang và cộng sự, Sec. III-B, (22) và mô tả hành động liên tục. Số công thức theo paper gốc.

PPO có xử lý ràng buộc

Reward: dùng utility U^k trong (14).
Cost: đo vi phạm độ trễ và độ tin cậy.

$$\widehat{A}^k_{\text{total}} = \widehat{A}^k_r - \lambda_1 \widehat{A}^k_{c,1} - \lambda_2 \widehat{A}^k_{c,2}. \tag{27}$$

- $\widehat{A}_r$: hành động tốt hơn mức kỳ vọng về reward bao nhiêu.
- $\widehat{A}_{c,i}$: mức bất lợi xét theo chi phí vi phạm.
- λ_i: tăng mức phạt khi vi phạm vượt ngưỡng cho phép.

Ý nghĩa: PPO cải thiện chính sách bằng cách cân đối lợi ích với vi phạm; cập nhật được giới hạn để tránh thay đổi quá mạnh.

RL xử lý chi phí tích lũy kỳ vọng; cơ chế này không trực tiếp bảo đảm accuracy (C8) ở mọi lần chạy.

Nguồn: Yang và cộng sự, Sec. III-C–D, (23)–(28). Số công thức theo paper gốc.

Chia sẻ chính sách giữa các UAV

$$a_u = \frac{\sum_m s^k_{m,u}}{\sum_{i\in\mathcal{U}} \sum_m s^k_{m,i}}, \qquad \theta_{\text{glob}} = \sum_u a_u \theta_u.$$

$$\theta_u \leftarrow \tau\theta_{\text{glob}} + (1-\tau)\theta_u.$$

θ_u	Tham số Actor của UAV u.
a_u	Trọng số theo số thiết bị đang được UAV phục vụ.
τ	Hệ số cập nhật mềm; chia sẻ mỗi E_{share} episode.

Ý nghĩa: Các UAV học hỏi chính sách của nhau, đồng thời giữ một phần thích nghi cục bộ.

Đổi ký hiệu trọng số từ w_u trong paper thành a_u trên slide để tránh nhầm với mô hình FL $\mathbf{w}^k_u$.

Nguồn: Yang và cộng sự, Sec. III-D, Thuật toán 2; công thức chia sẻ chính sách. Số công thức theo paper gốc.

Hai mô hình và hai giai đoạn hoạt động

	Mô hình FL $\mathbf{w}$	**Chính sách θ_u**
Mục đích	Học tác vụ từ dữ liệu thiết bị	Chọn lịch và phân bổ tài nguyên
Nơi học	Thiết bị IoT	Các tác tử UAV
Tổng hợp	Theo lượng dữ liệu	Theo số thiết bị phục vụ

Offline: huấn luyện FSTPO trong môi trường mô phỏng.

Online: UAV chạy Actor đã học để đưa ra s, b, f_m trong các vòng FL thực thi.

Điểm chính: FSTPO học cách quản lý tài nguyên cho hoạt động FL và offloading.

Nguồn: Yang và cộng sự, Sec. II-B, III, III-D. Số công thức theo paper gốc.

PHẦN 4

HƯỚNG MỞ RỘNG

Chọn tập thiết bị, đa mục tiêu và đa mức đánh giá

Hướng mở rộng: từ utility đến chất lượng học

Xuất phát từ FSTPO: điều khiển s, b, f để cân bằng utility FL thay thế, năng lượng và thời gian.

Bản thảo JNCA đề xuất:

- Giữ loss validation toàn quần thể làm mục tiêu chất lượng học.
- Xem giá trị dữ liệu theo cả tập client: dữ liệu hiếm có thể bổ trợ, gradient khác biệt cũng có thể do nhiễu.
- Tìm tập phương án Pareto thay vì chỉ một nghiệm ứng với bộ trọng số cố định.
- Giảm chi phí tìm kiếm bằng đánh giá đa mức; chỉ thu thập thông tin mới khi đáng chi phí.

Đây là working draft: các đóng góp và lợi ích cần thực nghiệm kiểm chứng.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 1–2, 4.

Mô hình mở rộng: ba mục tiêu

$$\min_{\pi} \mathbf{J}(\pi) = \left(\mathbb{E}[L_{\mathrm{val}}(w_K)],\ \mathbb{E}\left[\sum_{k=0}^{K-1} E_k\right],\ \mathbb{E}\left[\sum_{k=0}^{K-1} T_k\right] \right).$$

$$L_{\mathrm{val}}(w) = \sum_m p_m \frac{1}{|\mathcal{V}_m|} \sum_{\xi \in \mathcal{V}_m} \ell(w;\xi), \quad \sum_m p_m = 1.$$

- Input: checkpoint, lịch sử báo cáo, kênh, giới hạn tài nguyên và pin.
- Output: tập lịch khả thi Pareto; chọn một lịch theo ưu tiên triển khai đã định trước.
- p_m cố định theo quần thể mục tiêu; không đổi chỉ vì bỏ client khó phục vụ.
- Validation, training và test tách biệt; validation thực tế cần quyền truy cập và tính chi phí.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 2.1, 4; (3), (27).

Biến quyết định và ràng buộc mở rộng

Lõi ban đầu: $x = (s, b^T, f^T)$; tùy chọn probing thêm (z, b^P, f^P).

$$s_{m,u} \in \{0,1\}, \quad \sum_u s_{m,u} \le 1, \quad 0 \le b^T_{m,u} \le B_u s_{m,u}, \quad \sum_m b^T_{m,u} \le B_u.$$

$$f_m^{\min} s_m \le f_m^T \le f_m^{\max} s_m, \quad 1 \le \sum_m s_m \le N_{\max}.$$

$$T_k \le T_{\max}, \qquad B_i^{k+1} = B_i^k - E_i^k \ge B_i^{\text{reserve}}.$$

Ý nghĩa: Client không hoạt động nhận tài nguyên bằng 0; lịch phải thỏa khả dụng đường truyền, deadline và pin.

JNCA ban đầu dùng quỹ đạo cho trước, FL đồng bộ; offloading ứng dụng độc lập của FSTPO chưa nằm trong lõi này. Kết hợp hai bài cần thống nhất phạm vi chi phí.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 3–4; (14)–(16), (24), (28).

Hướng A: chọn tập client có tính bổ trợ

$$\Delta V(m \mid S) = \widehat{V}(S \cup \{m\}) - \widehat{V}(S).$$

Ví dụ của bản thảo: ba gradient vô hướng $(2, -2, 1)$, trọng số bằng nhau; gradient quần thể $\bar{g} = 1/3$.

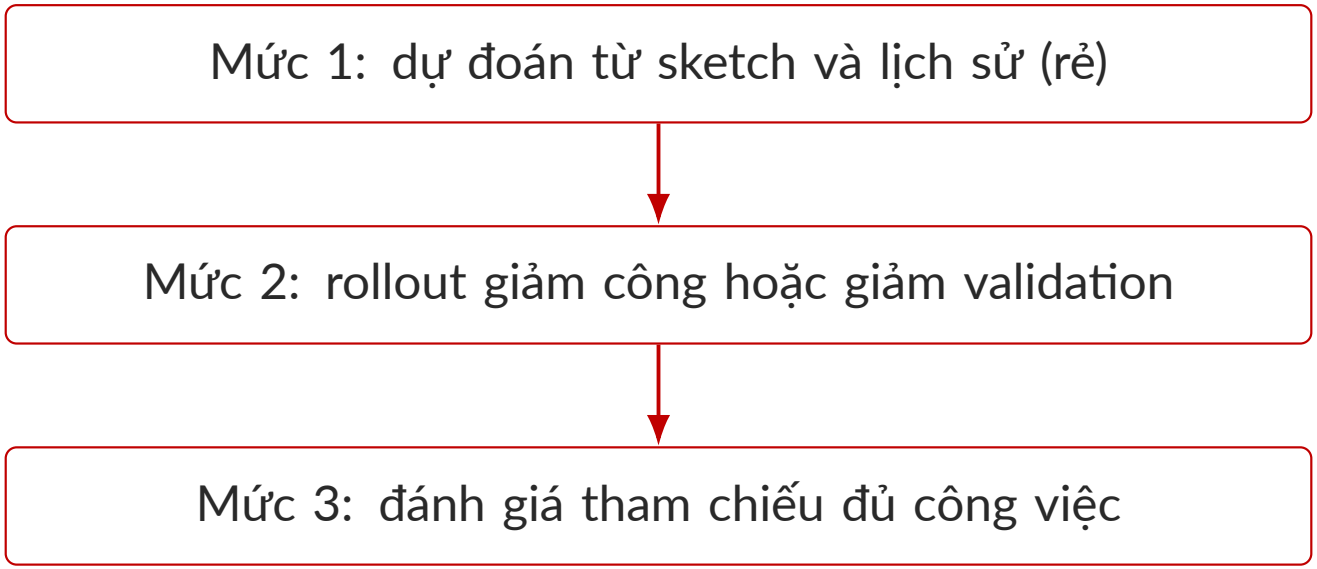
- Cặp $\{1, 2\}$ trung bình bằng 0, sai số bình phương $1/9$.
- Cặp $\{1, 3\}$ trung bình bằng 1.5, sai số $49/36$.
- Hai gradient rất khác nhau có thể bổ trợ tốt khi xét cùng nhau.

Thuật toán: sinh quần thể lịch khả thi $\rightarrow$ lai/đột biến tập client và tài nguyên $\rightarrow$ sửa ràng buộc $\rightarrow$ đánh giá $\rightarrow$ chọn theo Pareto và đa dạng.

Khớp gradient chỉ là proxy; phải kiểm tra loss validation. Giá trị biên có thể âm và không mặc định có tính submodular.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 2.2, 6; Algorithm 1.

Hướng B: đánh giá đa mức fidelity



Chỉ nâng mức các ứng viên có triển vọng hoặc cần khám phá; hiệu chuẩn sai lệch giữa các mức. Năng lượng/thời gian vật lý vẫn tính cho lịch đầy đủ.

Ý nghĩa: Dành đánh giá đắt cho ứng viên có thể cải thiện tập Pareto; không đồng nhất fidelity với probing vật lý.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 7; (37)–(42).

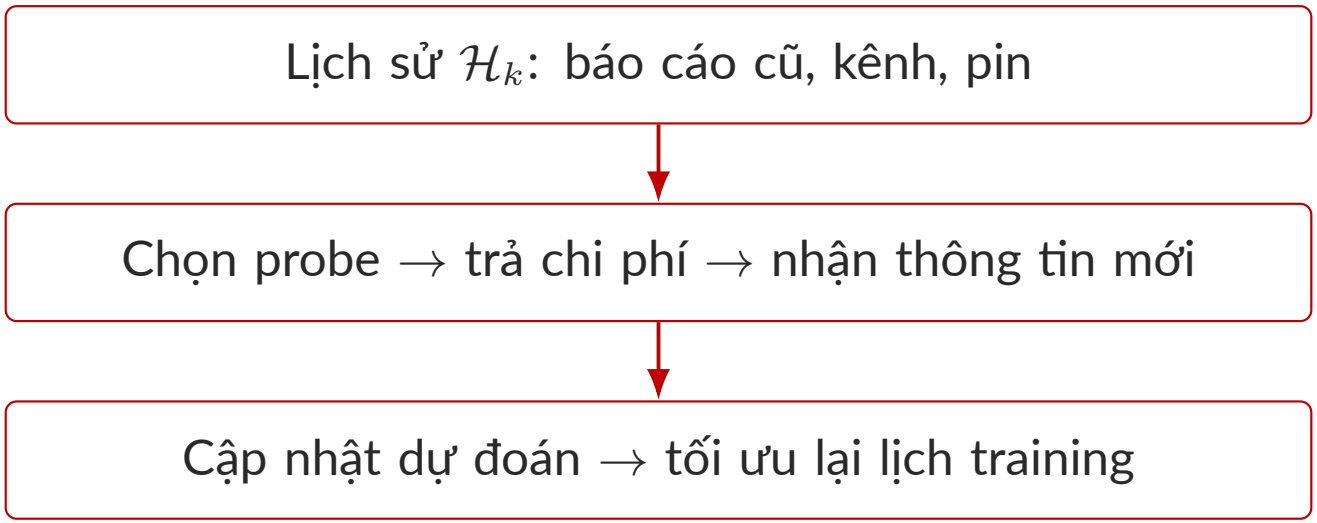
Mã giả tìm kiếm đa mức và kiểm chứng

1. Chốt snapshot, ngân sách tìm kiếm và ngân sách audit độc lập.
2. Sinh ứng viên; đánh giá tham chiếu một tập khởi tạo để hiệu chuẩn.
3. Lặp: lai/đột biến, sửa ràng buộc, tính chi phí vật lý và dự đoán loss rẻ.
4. Chọn ứng viên nâng fidelity theo lợi ích dự kiến trên chi phí; giữ tỷ lệ khám phá.
5. Cập nhật predictor và hai kho: dự đoán tạm thời, tham chiếu đã kiểm chứng.
6. Audit ứng viên cuối bằng cùng giao thức tham chiếu; tính lại quan hệ trội.
7. Chọn và thực thi một lịch theo ưu tiên đã khai báo.

Chỉ kho tham chiếu dùng để báo cáo chất lượng Pareto. Rollout giả lập không cập nhật checkpoint nguồn và không được tính là vòng FL thực thi.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 7; Algorithm 2.

Hướng C: probing và lập lịch lại



Probe có thể lấy loss minibatch và gradient sketch. Chọn cả phương án không probe; client vẫn có thể training mà không cần probe mới.

Ý nghĩa: Thông tin đáng mua khi có khả năng thay đổi quyết định đủ để bù chi phí tải mô hình, tính toán, upload và chờ.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 2.3, 8; Algorithm 3.

Đề xuất kết hợp với FSTPO

Ý tưởng tổng hợp của phần trình bày, cần kiểm chứng:

1. Dùng actor FSTPO sinh lịch khởi tạo khả thi cho tìm kiếm tiến hóa; bổ sung lịch ngẫu nhiên để giữ đa dạng.
2. Đánh giá lịch bằng bộ ba loss–energy–time; giữ baseline FSTPO trên cùng môi trường và ngân sách.
3. Dùng predictor đa fidelity để sàng lọc và tham chiếu để xác nhận các cải thiện.
4. Sau khi lõi ổn định, thêm tuổi thông tin và probing; mọi quyết định chỉ dùng quan sát được phép.

Đây không phải thuật toán đã được hai bài chứng minh. Có thể nghiên cứu scheduler tiến hóa độc lập trước; warm-start bằng FSTPO là một ablation bổ sung.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 6–10; liên hệ với Yang và cộng sự, Sec. III.

Lộ trình và tiêu chí kiểm chứng

1. Bắt đầu với 2 UAV, 6 client, cùng checkpoint; đặt client dữ liệu hiếm ở kênh yếu. Liệt kê tập con với phân bổ cố định để có mốc kiểm tra.
2. So sánh chọn ngẫu nhiên, greedy kênh, FSTPO, NSGA-II và chọn tập có tính bổ trợ trên cùng thông tin/tài nguyên.
3. Chỉ thêm đa fidelity nếu profiling chứng minh đánh giá tham chiếu đủ đắt và mức rẻ có ích.
4. Báo cáo Pareto đã audit, test accuracy/loss, rare-class recall, thời gian/năng lượng, vi phạm deadline và chi phí optimizer.
5. Ablation: bỏ set-aware, bỏ multi-fidelity, bỏ probing; so sánh với cùng chi phí tìm kiếm thực tế.

Ý nghĩa: Mục tiêu là chứng minh trade-off tốt hơn sau khi tính đủ chi phí, chưa khẳng định hiệu quả trước thực nghiệm.

Nguồn: Information-Aware Multiobjective Evolutionary Optimization, bản thảo nghiên cứu, Sec. 9–10.

Tài liệu tham khảo

1. Google Cloud. *Federated learning: a guide to what it is and how it works.*
   `https://cloud.google.com/discover/what-is-federated-learning`
   Truy cập ngày 15/10/2026.

2. X. Yang, J. Feng, L. Ma, L. Liu, Q. Pei và C. Wu.
   Federated Spatio-Temporal Policy Learning for Efficient Resource Management in UAV-Assisted IoT Edge Networks.
   IEEE Internet of Things Journal, bản tác giả được chấp nhận, 2026.
   `https://doi.org/10.1109/JIOT.2026.3727888`

3. H. B. McMahan và cộng sự. *Communication-Efficient Learning of Deep Networks from Decentralized Data.* AISTATS, 2017.
   `https://proceedings.mlr.press/v54/mcmahan17a.html`

Tài liệu bổ sung cho phần 1 và phần 4

- McMahan và cộng sự. *Communication-Efficient Learning of Deep Networks from Decentralized Data*. Bản arXiv 1602.05629v4, 26/01/2023; công bố gốc AISTATS 2017. Sec. 2, Algorithm 1 và phần thực nghiệm. `https://arxiv.org/abs/1602.05629`
- *Information-Aware Multiobjective Evolutionary Optimization with Multi-Fidelity Evaluation for UAV-Assisted Federated Learning*. Research Working Draft, bản PDF người dùng cung cấp, 13 trang. Sec. 1–10, Algorithms 1–3.

Phần 4 phân biệt đề xuất của bản thảo và ý tưởng kết hợp với FSTPO; chưa coi các giả thuyết nghiên cứu là kết quả đã kiểm chứng.